

¿Pueden los LLMs reemplazar los datos anotados? Generación de datos sintéticos para NER biomédico

Aitor Milicua Fernandez
Minería de Datos Textuales
Universidad del País Vasco (UPV/EHU)

Abstract

La anotación manual de texto biomédico (y en general) es costosa y requiere anotadores expertos. En este trabajo investigo si los datos sintéticos generados por un LLM pueden sustituir a los corpus anotados manualmente para entrenar modelos de Reconocimiento de Entidades Nombradas (NER), en este caso, en el dominio biomédico. Generamos corpus de entrenamiento sintéticos usando instruct prompting con Qwen2.5-3B-Instruct de forma local, con tres estrategias de prompt y distintos volúmenes de datos. Entrenamos BioBERT sobre cada corpus y evaluamos en el benchmark BC5CDR. Los resultados muestran una brecha significativa entre datos sintéticos y reales, aunque el rendimiento mejora con el volumen. Además, he documentado las limitaciones de los modelos locales pequeños para la generación de datos estructurados y he analizado los patrones de error sistemáticos de los modelos NER después del fine tuning.

1 INTRODUCCIÓN

El Reconocimiento de Entidades Nombradas (NER) en el dominio biomédico es una tarea fundamental para extraer información estructurada de la literatura científica. Los sistemas entrenados sobre corpus anotados manualmente alcanzan un buen rendimiento, pero producir esas anotaciones requiere un esfuerzo considerable por parte de expertos en el dominio (por lo general médicos, enfermeros..) (Li et al., 2016).

La aparición de modelos de lenguaje de gran tamaño (LLMs) capaces de seguir instrucciones complejas plantea una pregunta relevante: ¿pueden estos modelos generar datos de entrenamiento anotados que sustituyan la anotación humana? Este enfoque, conocido como *generación de datos sintéticos*, ha mostrado resultados prometedores en tareas generales de PLN, pero su efectividad en dominios especializados como la biomedicina no está clara.

En este trabajo exploraremos esta pregunta para NER biomédico usando el benchmark BC5CDR (Li et al., 2016), que cubre entidades de tipo Chemical y Disease. De forma concreta, nos planteamos las siguientes preguntas de investigación:

- ¿Puede un modelo entrenado exclusivamente con datos generados por un LLM aproximarse al rendimiento de uno entrenado con datos anotados por humanos?
- ¿Cómo afecta el volumen de datos sintéticos al rendimiento del modelo NER?
- ¿Influye la estrategia de prompting usada en la generación sobre la calidad de los datos?

2 METODOLOGÍA

2.1 Tarea y conjunto de datos

La tarea se formula como etiquetado de secuencias: dado un texto biomédico tokenizado, se asigna a cada token una etiqueta IOB2 del conjunto {0, B-Chemical, I-Chemical, B-Disease, I-Disease}. La entrada del modelo es una secuencia de tokens y la salida es una secuencia de etiquetas de la misma longitud.

He utilizado BC5CDR (Li et al., 2016), accedido a través del dataset tner/bc5cdr de HuggingFace. El corpus contiene 1.500 abstracts de PubMed anotados con menciones de entidades Chemical y Disease. Usamos la partición de entrenamiento (5.228 frases) exclusivamente para entrenar el modelo baseline, y reservamos la partición de test (5.865 frases) para evaluar todos los modelos, tanto los entrenados con los datos sintéticos como el benchmark.

2.2 Generación de datos sintéticos

He generado corpus de entrenamiento sintéticos usando **Qwen2.5-3B-Instruct** ejecutado de forma local en GPU. Cada llamada al modelo produce un

objeto JSON con un texto biomédico y una lista de menciones de entidades con sus etiquetas. Las menciones se convierten automáticamente a formato IOB2 mediante búsqueda exacta de cadenas con fallback morfológico por prefijo.

Evolución del pipeline de generación. Inicialmente se intentó usar la API de Gemini 2.0 Flash, pero fue descartada por límites de tasa muy restrictivos en el nivel gratuito. A continuación se probó la API de Inferencia de HuggingFace con el modelo Qwen2.5-72B-Instruct, pero los créditos mensuales se agotaron tras generar menos de 100 ejemplos. Finalmente se adoptó un enfoque de generación local con Qwen2.5-3B-Instruct, que proporciona capacidad de generación ilimitada a costa de una menor calidad en los textos producidos. Es importante mencionar que el conjunto de train del dataset original contiene sobre 5800 ejemplos, cosa que no he podido igualar por el tiempo que conlleva crear cada corpus con el modelo local

Estrategias de prompting. Se diseñaron tres variantes de prompt con niveles crecientes de información en contexto:

- **Zero-shot (ZS):** instrucciones y definición de las entidades únicamente.
- **Few-shot A (FSA):** instrucciones, definiciones y ejemplos de entidades aisladas (p. ej., *aspirin* → Chemical) para dar contexto al modelo.
- **Few-shot B (FSB):** instrucciones, definiciones y una frase completa anotada del conjunto de entrenamiento de BC5CDR como ejemplo real.

Volúmenes de datos. Para FSB se generan corpus de 100, 500 y 800 ejemplos con el objetivo de estudiar el efecto del volumen. Para ZS y FSA se generan 800 ejemplos cada uno, igualando el corpus FSB más grande para una comparación justa entre prompts.

La Tabla 1 resume las características de cada corpus generado frente a los datos reales de BC5CDR.

Los corpus sintéticos presentan mayor densidad de entidades que BC5CDR pero menor longitud media. Los corpus FSB son notablemente más cortos que ZS y FSA, probablemente porque el ejemplo en contexto restringe el estilo de generación del modelo pequeño. Una limitación recurrente es la baja diversidad léxica: en los corpus FSB se

Corpus	N	Long. media	Chem/ej.	Dis/ej.
BC5CDR (real)	5228	20.9	0.49	1.00
ZS-800	800	45.7	1.37	1.12
FSA-800	800	41.0	1.41	1.44
FSB-100	100	28.6	1.07	1.23
FSB-500	500	29.0	1.05	1.21
FSB-800	781	29.2	1.06	1.21

Table 1: Estadísticas de los corpus. Long. media = longitud media en tokens. Chem/ej. y Dis/ej. = media de entidades Chemical y Disease por ejemplo.

detectaron ejemplos repetidos, un fallo típico de modelos de instrucción pequeños.

A modo de ilustración, el siguiente ejemplo muestra un abstract generado con el prompt FSB: “A novel compound, *IL-17 inhibitor*, significantly reduces chronic inflammatory bowel disease symptoms in murine models.” con entidades anotadas IL-17 inhibitor (Chemical) e inflammatory bowel disease (Disease). Este tipo de abstractos son más cortos y directos que los de BC5CDR, que suelen describir estudios completos con metodología y resultados detallados.

2.3 Modelos y entrenamiento

Se realiza fine-tuning de **BioBERT** (dmis-lab/biobert-base-cased-v1.2) (Lee et al., 2020) para clasificación de tokens sobre cada corpus de forma independiente. BioBERT es un encoder basado en BERT pre-entrenado sobre abstracts de PubMed y artículos de PMC, lo que lo hace adecuado para NER biomédico.

Los hiperparámetros de entrenamiento son idénticos en todos los experimentos: 5 épocas, tasa de aprendizaje 2×10^{-5} , tamaño de batch 16, weight decay 0.01 y 100 pasos de warmup. Todos los experimentos se ejecutan en una GPU P100 de Kaggle.

Se entrenan seis modelos en total: un baseline sobre datos reales de BC5CDR y cinco sobre corpus sintéticos (FSB-100, FSB-500, FSB-800, ZS-800, FSA-800).

2.4 Evaluación

Todos los modelos se evalúan sobre la partición de test de BC5CDR (5.865 frases). Se reportan F1, Precisión y Recall a nivel de entidad calculados con seqeval, que exige coincidencia exacta de span y tipo. Este es el protocolo de evaluación estándar en benchmarks de NER biomédico. Adicionalmente, se realiza un análisis cualitativo de errores sobre el mejor modelo sintético, incluyendo una matriz

de confusión y la inspección de casos concretos de fallo.

3 RESULTADOS

La Tabla 2 muestra los resultados de todos los modelos sobre la partición de test de BC5CDR.

Modelo	F1	Prec.	Rec.
Baseline (BC5CDR)	0.883	0.865	0.902
ZS-800	0.318	0.693	0.206
FSA-800	0.339	0.627	0.233
FSB-100	0.036	0.040	0.032
FSB-500	0.322	0.554	0.227
FSB-800	0.371	0.677	0.255

Table 2: F1, Precisión y Recall a nivel de entidad sobre el test de BC5CDR. Todos los modelos sintéticos se entrenan exclusivamente con datos generados.

Existe una brecha significativa entre el baseline y todos los modelos sintéticos. El mejor modelo sintético (FSB-800) alcanza un F1 de 0.371, frente al 0.883 del baseline entrenado con datos reales, una diferencia de 0.512 puntos de F1.

Efecto del volumen de datos. La curva de aprendizaje del prompt FSB muestra una mejora pronunciada de FSB-100 (F1 0.036) a FSB-500 (F1 0.322), y más gradual de FSB-500 a FSB-800 (F1 0.371). El rendimiento casi nulo con 100 ejemplos sugiere la existencia de un umbral mínimo de datos por debajo del cual el modelo no aprende representaciones útiles a partir de datos sintéticos.

Efecto de la estrategia de prompting. Entre los corpus de 800 ejemplos, el rendimiento aumenta con la riqueza del prompt: ZS (0.318) < FSA (0.339) < FSB (0.371). Esto confirma que proporcionar más información en contexto durante la generación produce datos de mayor calidad, incluso con un modelo local pequeño.

Desequilibrio Precisión-Recall. Todos los modelos sintéticos presentan Precisión alta y Recall bajo. Esto indica un comportamiento conservador: los modelos predicen pocas entidades pero con cierta certeza cuando lo hacen. Este patrón es consistente en los seis experimentos y apunta a una limitación sistemática de los datos sintéticos generados.





Figure 1: Resultados experimentales. Izquierda: curva de aprendizaje del prompt FSB según el volumen de datos sintéticos. Derecha: comparación de F1 entre estrategias de prompting con 800 ejemplos



Comparativa entre tipos de entidad. Aunque la métrica principal es F1 global, el reporte detallado por tipo de entidad del mejor modelo sintético (FSB-800) revela diferencias importantes. Las entidades Chemical alcanzan F1 0.52, mientras que las entidades Disease obtienen únicamente F1 0.09. Los nombres de fármacos y compuestos químicos son léxicamente más distintivos y aparecen con mayor consistencia en los datos sintéticos, lo que facilita su aprendizaje. Las enfermedades, en cambio, presentan mayor variabilidad de expresión y contextos más ambiguos, lo que dificulta su detección cuando los datos de entrenamiento tienen poca diversidad.

Comparativa con el baseline por tipo de entidad. El baseline entrenado con datos reales muestra un rendimiento equilibrado entre Chemical y Disease, lo que refleja la riqueza y variedad del corpus BC5CDR anotado manualmente. La diferencia de rendimiento entre tipos de entidad en los modelos sintéticos es, por tanto, un efecto directo de las limitaciones del generador local y no una característica inherente de la tarea.

4 ANÁLISIS DE ERRORES

Para profundizar en los resultados cuantitativos, en este apartado vamos a analizar las predicciones del mejor modelo sintético (FSB-800) sobre el test de BC5CDR, guiandonos por las métricas obtenidas en la sección anterior. El objetivo es identificar qué tipos de fallos comete el modelo de forma sistemática y qué limitaciones de los datos sintéticos los explican.

4.1 Distribución de errores por tipo

La Tabla 3 muestra el recuento de errores clasificados en cuatro categorías: falsos negativos (entidades reales no detectadas), falsos positivos (tokens marcados como entidad cuando no lo son) y confusión entre tipos.

Tipo de error	Recuento
Falsos negativos Chemical	2.434
Falsos negativos Disease	3.978
Falsos positivos Chemical	532
Falsos positivos Disease	168
Confusión Chemical ↔ Disease	111

Table 3: Distribución de errores del modelo FSB-800 sobre el test de BC5CDR.

Los falsos negativos dominan claramente sobre los falsos positivos, especialmente en Disease. El modelo no detecta la mayoría de las entidades reales en lugar de predecir entidades incorrectas. Esto confirma el comportamiento conservador observado en el desequilibrio Precisión-Recall de la sección anterior.

La confusión entre tipos Chemical y Disease es relativamente baja (111 casos), lo que indica que el modelo sí aprende a distinguir ambos tipos cuando realiza una predicción, aunque lo hace con poca frecuencia.

4.2 Matriz de confusión

La Figura 2 muestra la matriz de confusión normalizada por fila para el modelo FSB-800.




Figure 2: Matriz de confusión normalizada por fila del modelo FSB-800 sobre el test de BC5CDR. Cada celda indica la proporción de tokens reales de cada clase que fueron predichos como cada etiqueta.

El modelo acierta en el 99% de los tokens sin entidad (clase O), lo que explica los valores altos de Precisión global. Sin embargo, el 45% de los tokens B-Chemical reales son clasificados como O, y el 90% de los tokens B-Disease reales también. Los tokens de continuación I-Chemical e I-Disease son prácticamente ignorados (83% y 76% clasificados como O respectivamente), lo que indica que el modelo apenas aprende a etiquetar entidades de múltiples tokens de forma correcta.

4.3 Análisis cualitativo

La inspección de casos concretos de error revela tres patrones recurrentes.

El primero es la **no detección de entidades poco frecuentes**. Nombres de fármacos como *Famotidine* no son detectados por el modelo, probablemente porque no aparecen en los datos sintéticos o aparecen con muy poca frecuencia. La baja diversidad léxica de los corpus generados por Qwen2.5-

3B limita la capacidad del modelo para generalizar a entidades no vistas.

El segundo patrón es la **confusión por contexto biomédico ambiguo**. El modelo marca como entidad tokens como *stress* o *H2* que en algunos contextos forman parte de compuestos o patologías, pero en las frases del test funcionan como términos contextuales. Esto refleja que los datos sintéticos no capturan suficientemente bien la ambigüedad léxica del dominio biomédico.

El tercer patrón es la **detección incompleta de entidades multi-token**. En algunos casos el modelo detecta el primer token de una entidad (B-) pero no sus continuaciones (I-), produciendo spans parciales. Este error es especialmente frecuente en entidades de enfermedad con varios términos, como *chronic obstructive pulmonary disease*.

5 CONCLUSIONES

En este trabajo he investigado si los datos sintéticos generados por un LLM pueden reemplazar los corpus anotados manualmente para NER biomédico. Los resultados muestran que, aunque los modelos entrenados con datos sintéticos aprenden a reconocer algunas entidades (F1 hasta 0.371), existe una brecha sustancial respecto al modelo baseline entrenado con datos reales (F1 0.883).

Otro hallazgo relevante es el desbalance observado en los corpus sintéticos generados. Los textos producidos por el modelo local presentan una densidad de entidades notablemente superior a la del corpus real (hasta 1.44 entidades Disease por ejemplo frente a 1.00 en BC5CDR), pero con menor variedad léxica. En los corpus FSB se detectaron ejemplos repetidos literalmente, lo que reduce la diversidad efectiva del conjunto de entrenamiento. Este desbalance entre cantidad aparente de entidades y diversidad real es una limitación crítica que los enfoques de generación sintética deben abordar.

Del análisis experimental se extraen tres conclusiones principales. En primer lugar, el volumen de datos sintéticos influye de forma significativa en el rendimiento: con solo 100 ejemplos el modelo apenas aprende, mientras que con 800 se alcanza el mejor resultado sintético. La curva de aprendizaje sugiere que serían necesarios volúmenes mayores para seguir mejorando. En segundo lugar, la estrategia de prompting afecta a la calidad de los datos generados. Proporcionar ejemplos completos del corpus real en el prompt (Few-shot B) produce datos de mayor calidad que los prompts con menos

información, lo que confirma la importancia del diseño del prompt en la generación de datos estructurados. En tercer lugar, los modelos entrenados con datos sintéticos presentan un comportamiento sistemáticamente conservador: alta Precisión y bajo Recall. Esto indica que los datos generados no son suficientemente diversos ni representativos del dominio para que el modelo aprenda a detectar la mayoría de las entidades.

Una limitación importante de este trabajo es el uso de un modelo local pequeño (Qwen2.5-3B-Instruct) para la generación. Los intentos iniciales con modelos más grandes a través de APIs externas (Gemini 2.0 Flash y Qwen2.5-72B a través de HuggingFace) fueron descartados por restricciones de créditos y límites de tasa. Es razonable esperar que modelos más grandes generen datos más diversos y de mayor calidad, lo que podría reducir la brecha con el baseline.

Como trabajo futuro, sería interesante explorar el uso de modelos generadores más grandes, aumentar el volumen de datos sintéticos más allá de los 800 ejemplos, y estudiar enfoques híbridos que combinen una pequeña cantidad de datos reales con datos sintéticos para mejorar el rendimiento en escenarios de baja disponibilidad de anotaciones.

Recursos

El código, los corpus generados y los resultados completos del trabajo están disponibles en el siguiente enlace: https://drive.google.com/file/d/1h7egWythvCoWjFFNdokpU4Vati86nKX3/view?usp=drive_link

References

- Jinhyuk Lee, Wonjin Yoon, Suho Kim, and 1 others. 2020. Biobert: a pre-trained biomedical language representation model for biomedical text mining. *Bioinformatics*, 36(4):1234–1240.
- Jiao Li, Yueping Sun, Robin J Johnson, and 1 others. 2016. Biocreative v cdr task corpus: a resource for chemical disease relation extraction. In *Database*.